Proyecto Final – Agente Inversor con DQN

Erwin Arnoldo Daza Rendón

Nicolás Rozo Hincapié

Fabián Eduardo Ruiz Sánchez

Andrés Enrique Pachón Bustos

Facultad de Ingeniería, Universidad de La Sabana

Simulación y Aprendizaje por Refuerzo

Dr. (c) Emilio Muñoz Pérez

20 de octubre de 2026

TABLA DE CONTENIDO

I. INTRODUCCIÓN 3
II. CONCEPTOS FINANCIEROS BÁSICOS 3
III. COMPONENTES TÉCNICOS UTILIZADOS PARA RESOLVER EL PROBLEMA DEL AGENTE INVERSOR .. 4
IV. FORMULACIÓN DEL PROBLEMA COMO REINFORCEMENT LEARNING 10
V. ESTADO ¿Qué observa el agente? 12
VI. ESPACIO DE ACCIONES 14
VII. DATOS 14
VIII. ANÁLISIS EXPLORATORIO DE LOS DATOS 16
IX. IMPLEMENTACIÓN DEL ENTORNO 19
X. DISEÑO DE LA RECOMPENSA 20
XI. ALGORITMO DE REINFORCEMENT LEARNING 22
XII. BASELINES 23
XIII. PROTOCOLO DE ENTRENAMIENTO Y EVALUACIÓN 25
XIV. MÉTRICAS 26
XV. RESULTADOS 29
XVI. REFLEXIÓN 30
XVII. REPRODUCIBILIDAD 32
XVIII. REFERENCIAS 32

I. INTRODUCCIÓN

En los mercados financieros, una de las decisiones básicas de un inversionista es determinar cuándo invertir y cuánto capital exponer al mercado.

Suponga que tiene $100.000 y está siguiendo el precio de un activo. En cada momento puede decidir no invertir, invertir la mitad de su capital o invertir todo. Después de tomar la decisión, el precio cambia y el valor de la inversión aumenta o disminuye. En el siguiente momento, el inversionista vuelve a observar la información disponible y puede tomar una nueva decisión.

Este proceso puede representarse como una secuencia de decisiones:

Observar el mercado → Tomar una acción → El precio cambia → Obtener una recompensa → Volver a decidir

Esto hace que la inversión sea un problema natural para **Reinforcement Learning (RL)**: un agente toma decisiones de manera secuencial, interactúa con un entorno y aprende a partir de las consecuencias de sus acciones.

El objetivo de esta actividad es construir un agente que aprenda una estrategia de inversión utilizando datos históricos de mercado y comparar su comportamiento con estrategias sencillas.

El objetivo no es simplemente obtener el mayor retorno histórico. Una estrategia puede generar grandes ganancias durante un período y posteriormente sufrir pérdidas importantes. Además, realizar demasiadas operaciones genera costos. Por esta razón, será necesario considerar el rendimiento, el riesgo y los costos asociados a las decisiones del agente.

La pregunta central del proyecto es:

¿Puede un agente de Reinforcement Learning aprender una estrategia de inversión que se comporte mejor que estrategias simples cuando se enfrenta a datos que no ha visto durante su entrenamiento?

Un resultado negativo no implica necesariamente un mal proyecto. La rigurosidad de la formulación, la evaluación y el análisis es más importante que obtener un retorno elevado.

II. CONCEPTOS FINANCIEROS BÁSICOS

Precio: El precio es el valor al que se negocia un activo en un determinado momento. Si un activo pasa de $100 a $105, su retorno es:

Retorno = (105 − 100) / 100 = 5 %

Retorno: El retorno mide cuánto aumentó o disminuyó el valor de una inversión durante un período. Si una inversión de $100.000 obtiene un retorno del 5 %, su valor pasa aproximadamente a $105.000.

Posición: La posición representa cuánto capital está actualmente expuesto al activo.

- 0 %: no tiene capital invertido.
- 50 %: la mitad del capital está invertida.
- 100 %: todo el capital está invertido.

En esta actividad se recomienda comenzar con un espacio de acciones discreto, por ejemplo, A = {0 %, 50 %, 100 %}.

Comprar y mantener: Comprar y mantener (**buy** and **hold**) significa comprar el activo al comienzo del período y mantener la posición durante toda la evaluación, sin intentar decidir cuándo entrar o salir. Esta estrategia será uno de los principales **baselines** contra los cuales se comparará el agente.

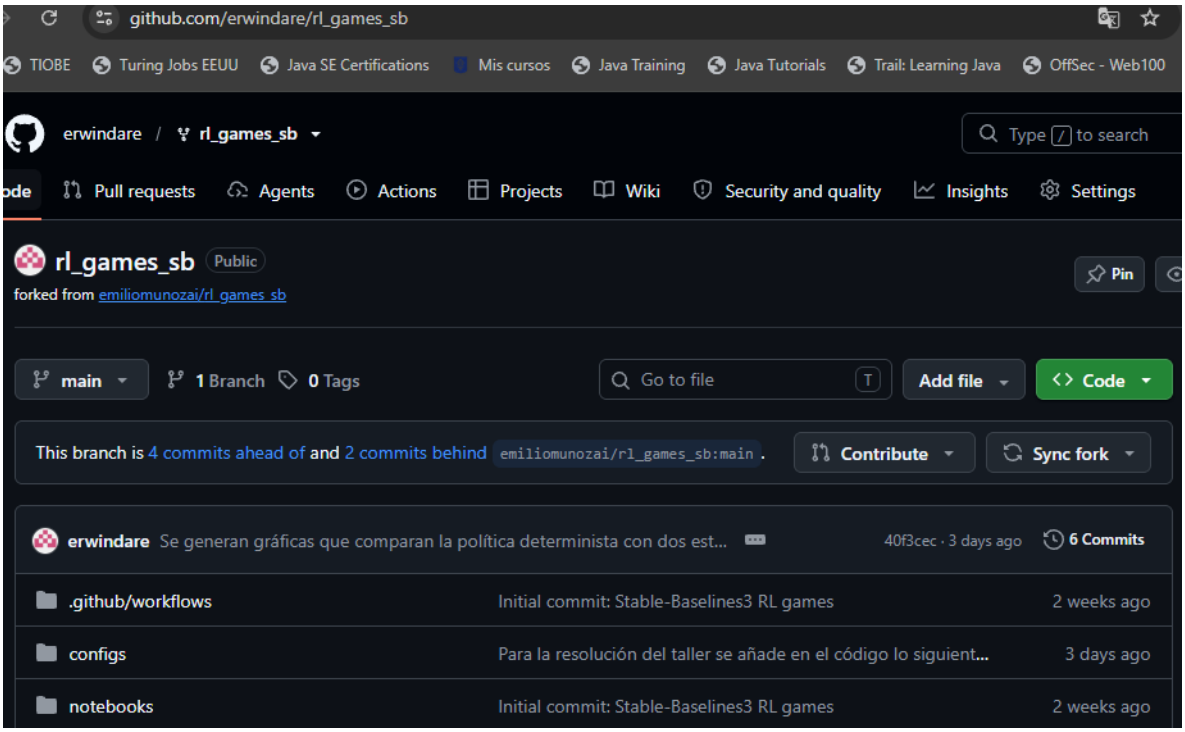
Costos de transacción: Comprar o vender un activo puede tener un costo. Para simplificar el problema, se incorporará un costo cada vez que el agente modifique su posición. Por ejemplo, 10 basis points (bps) equivalen a 0,10 %. Una estrategia que cambia constantemente de posición puede terminar destruyendo parte de sus ganancias por costos de operación.

Drawdown: El drawdown mide la caída del valor de una inversión desde un máximo anterior. Si un portafolio aumenta de $100.000 a $150.000 y posteriormente cae a $120.000, el drawdown es −20 %. Por esta razón, no se debe evaluar una estrategia únicamente por su retorno.

III. COMPONENTES TÉCNICOS UTILIZADOS PARA RESOLVER EL PROBLEMA DEL AGENTE INVERSOR

Se procede a realizar una copia personal e independiente en la cuenta propia de GitHub, del repositorio base aportado en el curso. El repositorio base es: https://github.com/emiliomunozai/rl_games_sb. La copia de acceso Público se realiza en la cuenta de GitHub de Erwin Daza: https://github.com/erwindare/rl_games_sb como se puede evidenciar en la siguiente imagen:

Figura 1. *Fork del repositorio base de GitHub*



Una vez realizada esta copia se Clona localmente el proyecto para realizar los ajustes requeridos para el Proyecto. Ya teniendo todo dispuesto localmente, se procede a revisar el archivo **README.md** para entender la estructura del proyecto, los comandos de ejecución de los agentes ya implementados (entre ellos DQN) y los componentes y dependencias externas utilizadas.

Entre los componentes externos se encuentran:

ENTORNOS DE TRADING:

El proyecto base utiliza la dependencia **gym-anytrading**, la cual es una colección de entornos **OpenAI-Gym** para algoritmos de negociación basados en aprendizaje por refuerzo. Los algoritmos de trading se implementan principalmente en dos mercados: **FOREX**[1] (mercado de divisas) y **STOCKS**[2] (acciones o existencias). En el archivo **envs.py** del proyecto se evidencia el uso de estos dos entornos:

Figura 2. *Uso de Forex y Stocks en el proyecto base*

[1] FOREX: mercado global descentralizado o extrabursátil (OTC) para la negociación o intercambio de monedas.
[2] STOCKS: Las acciones (también capital social o, a veces indistintamente, participaciones) consisten en todas las participaciones mediante las cuales se divide la propiedad de una corporación o empresa.

envs.py 2

RL > repo_taller3_final > rl_games_sb > src > rl_games_sb > envs.py > TRADING_ENV_IDS

```python
"""Environment construction.

Contents:
  - DEFAULT_ENV_ID  : the env used when none is given
  - TRADING_ENV_IDS : the gym-anytrading envs
  - FireOnNewLife   : wrapper that presses FIRE at the start of each life
  - make()          : construct standard, Atari-preprocessed, or portfolio
                      trading environments
"""
import ale_py
import gym_anytrading
import gymnasium as gym
from stable_baselines3.common.monitor import Monitor

# Third-party envs register their ids on import: ALE/... (Atari) and
# stocks-v0 / forex-v0 (trading).
gym.register_envs(ale_py)
gym.register_envs(gym_anytrading)

DEFAULT_ENV_ID = "LunarLander-v3"
TRADING_ENV_IDS = ("stocks-v0", "forex-v0")
```

AnyTrading busca proporcionar entornos **Gym** para mejorar y facilitar el desarrollo y la prueba de algoritmos basados en aprendizaje por refuerzo en este ámbito. Este objetivo se logra mediante la implementación de tres entornos Gym: **TradingEnv**, **ForexEnv** y **StocksEnv**. Para más detalle sobre la implementación Python de estos entornos ir a https://github.com/AminHP/gym-anytrading.

DATASETS PARA ENTRENAMIENTO: (Históricos de mercados divisas y acciones)

Siguiendo el objetivo de este proyecto de que el agente a construir aprenda una estrategia de inversión utilizando datos históricos de mercado, los entornos **FOREX** (**forex-v0**) y **STOCKS** (**stocks-v0**) **ya contienen dos DataSets del histórico del mercado de divisas y del mercado de acciones respectivamente**. Estos DataSets se denominan:

- **FOREX_EURUSD_1H_ASK.csv**
- **STOCKS_GOOGL.csv**

Figura 3. *FOREX_EURUSD_1H_ASK.csv (incluido por defecto en forex-v0)*

1	Time	Open	High	Low	Close	Volume
2	01.01.2017 22:00:00.000	1.05236	1.05253	1.05221	1.05227	143539993.3
3	01.01.2017 23:00:00.000	1.05227	1.05426	1.05226	1.05282	253139999.4
4	02.01.2017 00:00:00.000	1.05283	1.05283	1.05268	1.05281	131399993.9
5	02.01.2017 01:00:00.000	1.05282	1.05286	1.05225	1.0524	273940002.4
6	02.01.2017 02:00:00.000	1.05239	1.0524	1.05164	1.0522	258140014.6
7	02.01.2017 03:00:00.000	1.05219	1.05244	1.05184	1.05226	2288179932
8	02.01.2017 04:00:00.000	1.05226	1.05232	1.05181	1.05193	711799987.8
9	02.01.2017 05:00:00.000	1.05195	1.05197	1.05136	1.05161	288209991.5
10	02.01.2017 06:00:00.000	1.05163	1.05176	1.05113	1.05172	390880004.9
11	02.01.2017 07:00:00.000	1.05171	1.05243	1.05129	1.05162	3070070068
12	02.01.2017 08:00:00.000	1.05159	1.05188	1.04878	1.04899	6903950195
13	02.01.2017 09:00:00.000	1.04899	1.04932	1.04779	1.04877	6126959961

Este dataset contiene 6.225 registros y 6 variables como se evidencia en la imagen anterior. Representa una serie temporal histórica estructurada para entrenar algoritmos de Aprendizaje por Refuerzo (RL). Opera con el par EUR/USD, tiene una periodicidad de 1 hora (1H) y los precios corresponden al precio de oferta (Ask). Sus variables indican:

- **Time (índice temporal)**: Son la fecha y la hora exacta en la que se abrió la vela de 1 hora. Actúa como el identificador único de cada fila y organiza el dataset de forma cronológica ascendente para que el agente procese la información secuencialmente.

- **Open (apertura)**: Es el precio de cotización del par EUR/USD en el **primer segundo** del inicio de esa hora específica. Muestra el estado inicial del precio al comenzar el ciclo de 60 minutos.

- **High (máximo)**: Es el precio **más alto** alcanzado por el par EUR/USD durante esa hora. Registra el punto máximo de presión compradora o el techo alcanzado antes de que terminara el periodo.

- **Low (mínimo)**: Es el precio más bajo registrado por el par EUR/USD dentro de esa hora. Muestra el suelo o el punto de mayor devaluación/presión vendedora del ciclo.

- **Close (cierre)**: Es el precio de cotización en el **último segundo** de esa hora. Es una de las variables más cruciales, ya que el entorno gym-anytrading la utiliza directamente (junto con su diferencia respecto a la vela anterior) para calcular los retornos financieros de las posiciones **Buy** (Compra) o **Sell** (Venta) que toma el agente.

Figura 4. *STOCKS_GOOGL.csv (incluido por defecto en stocks-v0)*

1	Date	Open	High	Low	Close	Adj Close	Volume
2	2009-05-22	198.528534	199.524521	196.196198	196.946945	196.946945	3433700
3	2009-05-26	196.171173	202.702698	195.195190	202.382385	202.382385	6202700
4	2009-05-27	203.023026	206.136139	202.607605	202.982986	202.982986	6062500
5	2009-05-28	204.544540	206.016022	202.507507	205.405411	205.405411	5332200
6	2009-05-29	206.261261	208.823822	205.555557	208.823822	208.823822	5291100
7	2009-06-01	209.574570	215.015015	209.474472	213.493500	213.493500	6638100
8	2009-06-02	213.338333	215.195190	211.911911	214.414413	214.414413	5241900
9	2009-06-03	213.213211	216.446442	212.212219	216.041046	216.041046	7058500
10	2009-06-04	217.867874	220.840836	217.467468	220.360367	220.360367	7268900
11	2009-06-05	222.757751	223.893890	219.949951	222.382385	222.382385	7354200
12	2009-06-08	219.969971	220.680679	217.277283	219.604599	219.604599	6191200
13	2009-06-09	219.509506	220.470474	216.096100	218.028030	218.028030	6503200

Este dataset contiene 2.335 registros y 7 variables como se evidencia en la imagen anterior. Contiene los datos históricos de cotización diaria de las acciones de Alphabet Inc. (Google). A diferencia del mercado Forex (que opera 24 horas continuas con alta periodicidad), este archivo representa un mercado accionario tradicional, por lo que su periodicidad es diaria (1D) y cuenta con una columna adicional clave: el volumen de transacciones. A continuación se detalla el significado y comportamiento de cada variable dentro del dataset:

- **Date (índice temporal)**: Indica el día específico (Año-Mes-Día) en el que ocurrieron las cotizaciones de la fila.

- **Open (apertura)**: Es el precio con el que comenzó a cotizar la acción de Google al abrirse la sesión del mercado financiero (por ejemplo, a las 9:30 AM EST en la bolsa de Nueva York).

- **High (máximo)**: El precio más alto que alcanzaron las acciones de Google durante toda la jornada de ese día.

- **Low (mínimo)**: El precio más bajo registrado para la acción durante la jornada de ese día.

- **Close (cierre)**: El precio oficial al que finalizó la cotización de la acción cuando cerró el mercado regular (por ejemplo, a las 4:00 PM EST); stocks-v0 para simular la ejecución de operaciones financieras. Con base en este valor se calculan las ganancias (total_profit) y pérdidas acumuladas.

- **Volume (volumen)**: Representa la cantidad total de acciones de Google que cambiaron de manos (se compraron y vendieron) durante ese día. En análisis cuantitativo, el volumen valida la fuerza de una tendencia (un cambio de precio con mucho volumen es más significativo que uno con poco volumen).

ALGORITMO DQN:

El proyecto base utiliza la dependencia **stable-baselines3**, la cual es un conjunto de implementaciones de algoritmos de aprendizaje por refuerzo en **PyTorch**. Entre estas implementaciones se encuentra el algoritmo DQN el cual es una Red Neuronal Profunda Q (DQN) que se basa en la iteración Q ajustada (FQI) y utiliza diferentes técnicas para estabilizar el aprendizaje: utiliza un búfer de reproducción, una red objetivo y recorte de gradiente. DQN tiene disponibles las siguientes políticas:

Tabla 1. *Políticas disponibles en DQN*

MlpPolicy	
CnnPolicy	Clase de política para DQN cuando se utilizan imágenes como entrada
MultiInputPolicy	Clase de política para DQN cuando se utilizan observaciones de diccionario como entrada

En el archivo **registry.py** del proyecto base se encuentran las invocaciones de los algoritmos de stable-baselines3, entre ellos DQN:

Figura 5. *Uso de DQN en el proyecto base*

registry.py 3

RL > repo_taller3_final > rl_games_sb > src > rl_games_sb > registry.py > ...

```python
"""Algorithm lookup, save paths, and construction.

Contents:
  - SAVE_DIR        : directory holding saved models
  - ALGOS           : algorithm key -> Stable-Baselines3 class
  - ALGO_CHOICES    : the valid algorithm keys
  - save_path()     : save file for an (algorithm, env) pair
  - create()        : build a fresh, untrained model
  - load()          : load a saved model
  - load_or_create(): load if a save exists, else create
  - describe_device(): a device as printed by the CLI, e.g. "cuda (RTX 5070 Ti)"
"""
from pathlib import Path

import torch
from stable_baselines3 import A2C, DQN, PPO
from stable_baselines3.common.base_class import BaseAlgorithm
from stable_baselines3.common.utils import get_device

from rl_games_sb import envs

SAVE_DIR = Path("saves")

# Adding an algorithm = a row.
ALGOS: dict[str, type[BaseAlgorithm]] = {"dqn": DQN, "ppo": PPO, "a2c": A2C}
```

Para más detalle sobre la implementación del algoritmo DQN ir a https://stable-baselines3.readthedocs.io/en/master/.

IV. FORMULACIÓN DEL PROBLEMA COMO REINFORCEMENT LEARNING

Siguiendo la estrategia formal: ***St → At → Rt+1, St+1***. Donde **St** es el estado u observación del mercado, **At** es la acción, **Rt+1** es la recompensa y **St+1** es la nueva observación, el problema se formuló como control secuencial de una **cartera long-only**[3]. En cada decisión, **el estado es un vector float32 de siete componentes calculadas con precios de cierre hasta t**: retorno de 1 período, momentum[4] de 5 y 20 períodos, volatilidad de 20 retornos logarítmicos, distancia relativa a SMA-20, RSI-14 re-escalado entre 0 y 1 y exposición actual. **La observación tiene la misma definición para Acciones y Forex**; cambian la frecuencia y el conjunto histórico de datos para entrenamiento.

[3] Cartera long-only: Es una estrategia de inversión en la que el gestor o inversor sólo compra activos (como acciones, bonos o fondos) con la expectativa de que suban de valor, sin realizar ventas en corto (short selling) ni apostar a las caídas del mercado.

[4] Momentum:es la tendencia de un activo (acción, divisa o índice) a continuar moviéndose en la misma dirección, ya sea al alza o a la baja, durante un periodo determinado.

La acción es un objetivo de exposición {0; 0,5; 1}, no una orden de compra/venta. **La transición lleva el precio de Close[t] a Close[t+1]**, **descuenta el costo de cambiar la exposición**, **actualiza el patrimonio** y **devuelve el siguiente estado**, **recompensa** y **fin de segmento**. El estado incorpora la posición para que el agente pueda estimar el costo de cambiarla.

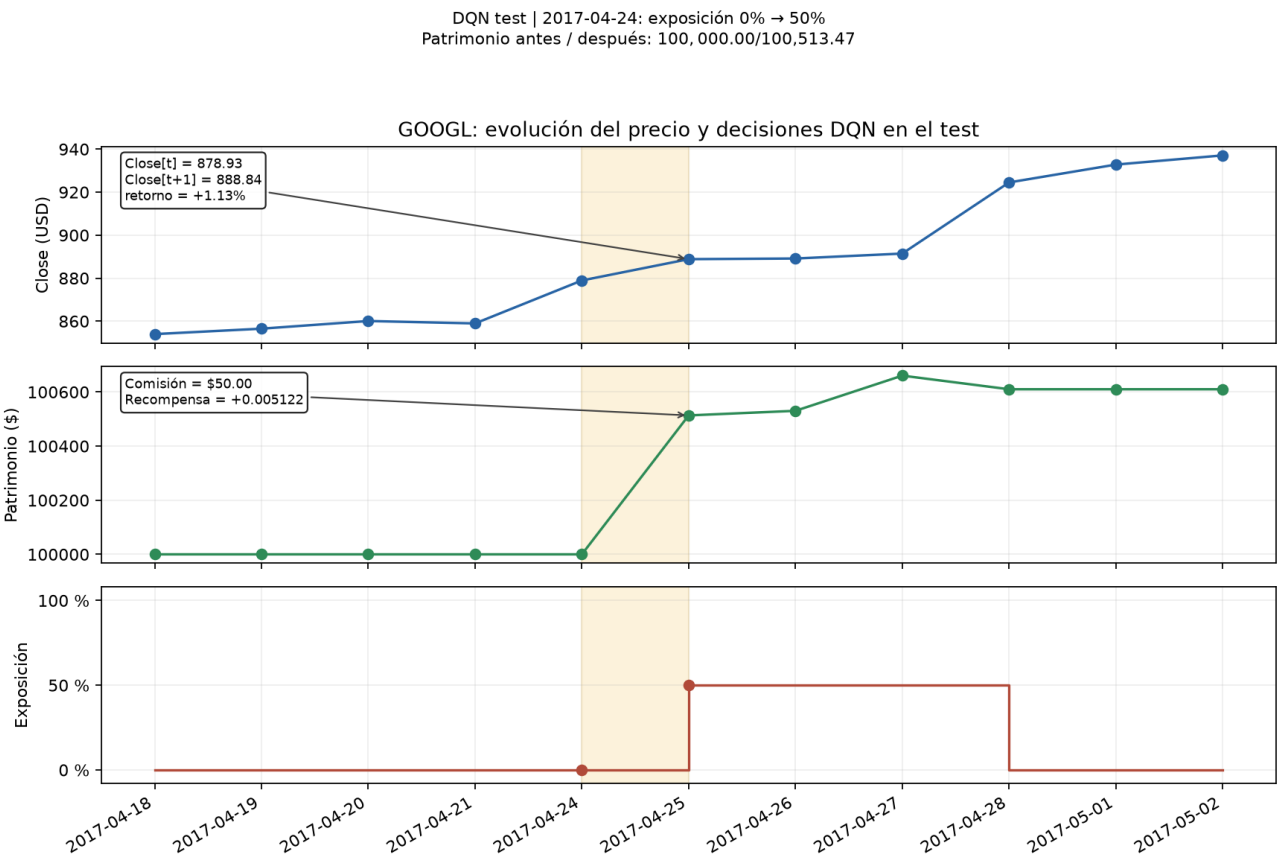
La Tabla 2 recorre una transición real del DQN en el tramo de prueba de STOCKS_GOOGL: la decisión se toma al cierre del 24 de abril de 2017 y su efecto se mide al cierre siguiente. Se usan el capital inicial del entorno (USD 100.000), una comisión de 10 puntos básicos y la recompensa logarítmica configurada para stocks.

Tabla 2. *Traza numérica de una transición DQN en el test de STOCKS_GOOGL.*

Etapa	Ejemplo numérico GOOGL	Qué ocurre
Observación S_t	Close[t] = USD 878,93; S_t = [0,023261; 0,027832; 0,052434; 0,007353; 0,034125; 0,673457; 0]	Cierre del 24-abr-2017; solo información disponible hasta t.
Acción A_t	Acción 1: objetivo 0,5; exposición previa 0; turnover 0,5.	Asignación del 50 %, no cantidad fija de títulos.
Precio	Close[t+1] = USD 888,84; retorno +1,1275 %.	El movimiento ocurre tras decidir.
Costo	USD 100.000 × 0,5 × 0,001 = USD 50,00.	10 pb sobre patrimonio previo y turnover.
Patrimonio	V[t+1] = 100.000 × (1 - 0,5 × 0,001) × (1 + 0,5 × 0,0112751) = USD 100.513,47.	Se descuenta costo y aplica retorno a exposición nueva.
Reward	ln(100.513,47 / 100.000) = +0,005122.	Retorno logarítmico neto, no dólares.
Siguiente estado	[0,011275; 0,040808; 0,060023; 0,007588; 0,042697; 0,760398; 0,5].	Al cierre del 25-abr se recalculan indicadores.

Nota: El estado ordena return_1, momentum_5, momentum_20, volatility_20, price_vs_sma_20, rsi_14 y current_exposure. Valores redondeados; tarifa de 10 pb (0,001).

Figura 6. *Precio, patrimonio y exposición alrededor de una transición del 24 al 25 de abril de 2017.*



V. ESTADO ¿Qué observa el agente?

El estado contiene la información disponible para el agente en el momento t. El agente no debe recibir información que todavía no estaba disponible cuando tomó la decisión. El estado exacto y su orden son: return_1 = Close[t]/Close[t−1]−1; momentum_5 = Close[t]/Close[t−5]−1; momentum_20 = Close[t]/Close[t−20]−1; volatility_20 = desviación estándar de hasta 20 retornos logarítmicos anteriores; price_vs_sma_20 = Close[t]/promedio(Close[t−19:t])−1; rsi_14 = ganancia media positiva/(ganancia media positiva+pérdida media absoluta), en escala 0–1; current_exposure {0; 0,5; 1}. La SMA usa 20 cierres y el RSI hasta 14 retornos. No se añaden indicadores OHLCV distintos del cierre al estado.

El retorno reciente informa el último impulso; los dos momentum comparan tendencias de distinta duración; la volatilidad aproxima el riesgo reciente; la desviación de SMA-20 contextualiza el cierre frente a su nivel reciente; el RSI resume el balance de movimientos positivos y negativos, sin que por sí solo prediga una reversión; y la exposición actual hace observable el costo por turnover[5]. En los

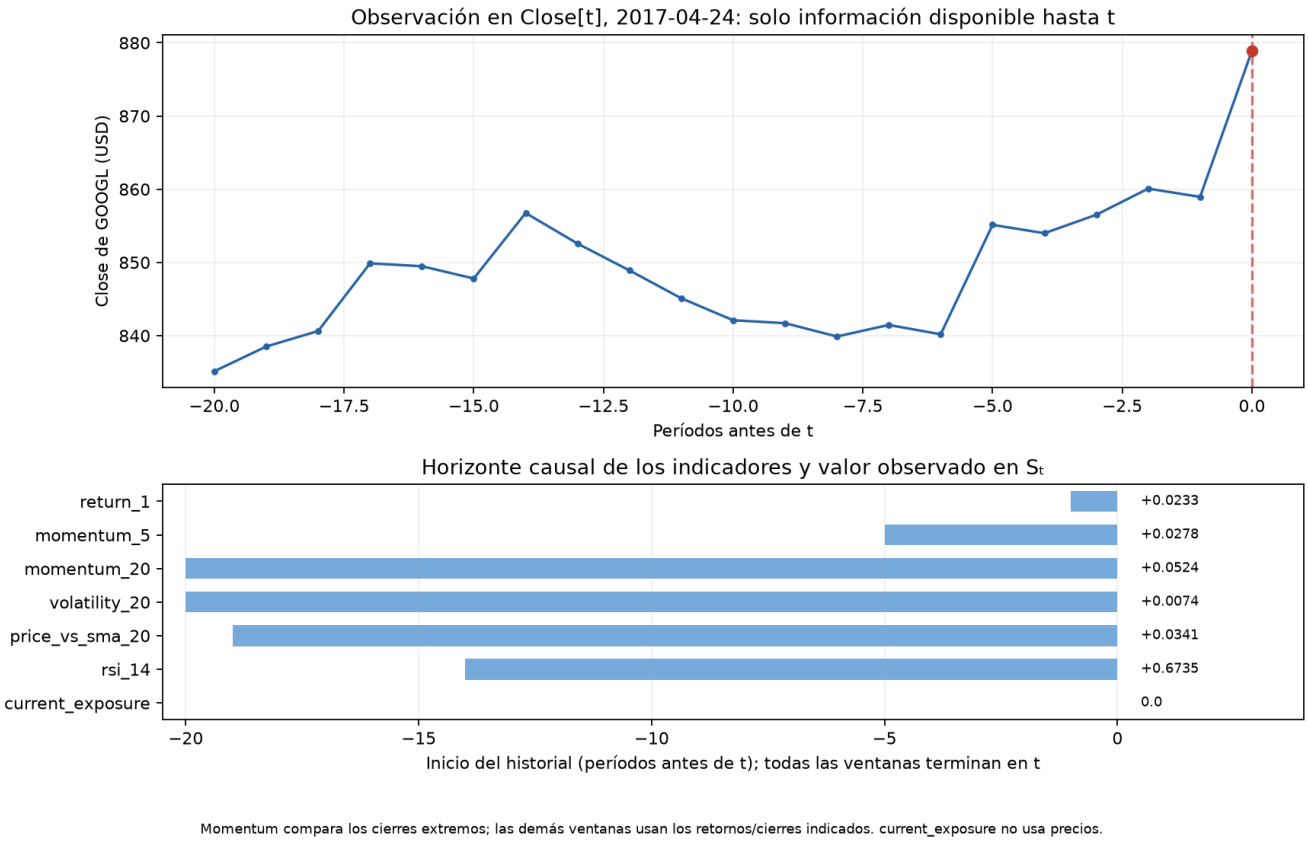
[5] Costo por turnover (costo por rotación de cartera): es el conjunto de gastos directos e indirectos que se generan cuando el gestor de un fondo ETF o una cartera individual compra y vende activos (acciones, bonos) con frecuencia.

datos activos, el momentum-20 fue de −20,59 % a +30,34 % en STOCKS_GOOGL y de −1,66 % a +1,70 % en FOREX_EUR/USD. La distancia a SMA-20 osciló entre −14,17 % y +23,81 % en STOCKS_GOOGL y entre −1,02 % y +1,70 % en FOREX_EUR/USD. La media de volatilidad-20 fue 1,35 % por sesión en STOCKS_GOOGL y 0,083 % por hora en FOREX_EUR/USD; sus unidades y frecuencias no son comparables directamente.

No hay normalización ajustada con la serie completa ni ventanas centradas. Cada característica es una función causal de cierres pasados y el actual. Al cruzar límites temporales, se permite mirar hacia atrás para inicializar las ventanas, pero no se recompensa ningún movimiento que salga del segmento. La prueba automatizada modifica todos los cierres futuros y comprueba que la observación inicial no cambia. La selección de indicadores y los hiperparámetros no se ajustaron con el resultado de test.

La Figura 7 amplía el estado observado en el mismo instante de decisión (cierre del 24 de abril de 2017). La serie muestra cierres históricos disponibles y las barras señalan el horizonte de cada indicador; todas terminan en t. current_exposure proviene de la posición anterior, no de una ventana de precios.

Figura 7. *Cierres disponibles y horizontes de cálculo del estado en Close[t] (STOCKS_GOOGL, 24-abr-2017).*



VI. ESPACIO DE ACCIONES

DQN elige una de tres exposiciones objetivo: acción 0 = 0 % (cartera en efectivo para el intervalo), acción 1 = 50 % (mitad del patrimonio expuesta a una posición larga) y acción 2 = 100 % (posición larga con todo el patrimonio). Al reset, el capital inicial es $100.000 y la exposición es cero. **Se eligieron tres acciones discretas para que la salida sea compatible con DQN** y permitir efectivo, exposición parcial y total con una interpretación económica sencilla.

La representación no permite vender en corto, apalancarse, elegir una fracción arbitraria, cambiar exposición intraperíodo, decidir tamaño por número de títulos ni incorporar límites de liquidez/ejecución. Tampoco es una acción «comprar una vez»: es un nivel de exposición que se mantiene hasta la siguiente decisión; un cambio de nivel genera turnover y costo.

La Tabla 3 resume el espacio discreto implementado. Cada acción define la exposición objetivo que se mantiene hasta la siguiente decisión; si cambia la exposición, el entorno cobra el costo proporcional al turnover.

Tabla 3. *Acciones discretas y su interpretación para la cartera.*

Acción / objetivo	Significado económico	Límite o efecto
0 → 0 %	Mantener patrimonio en efectivo durante el intervalo.	Cambio desde otra exposición genera costo.
1 → 50 %	Exposición larga parcial; mitad del patrimonio expuesta.	Retorno/pérdida afectan proporcionalmente.
2 → 100 %	Exposición larga completa.	Máximo permitido; no hay apalancamiento.
No disponibles	Cortos, apalancamiento o fracciones arbitrarias.	No fija títulos, liquidez ni ejecución intraperíodo.

VII. DATOS

El agente inversor utilizó los datasets **FOREX_EURUSD_1H_ASK.csv** y **STOCKS_GOOGL.csv** incluidos en los entornos **forex-v0** y **stocks-v0** respectivamente de la librería **gym_anytrading**. El detalle de estos datasets se explicó en el punto 3 de este documento (*componentes técnicos utilizados para resolver el problema del agente inversor*).

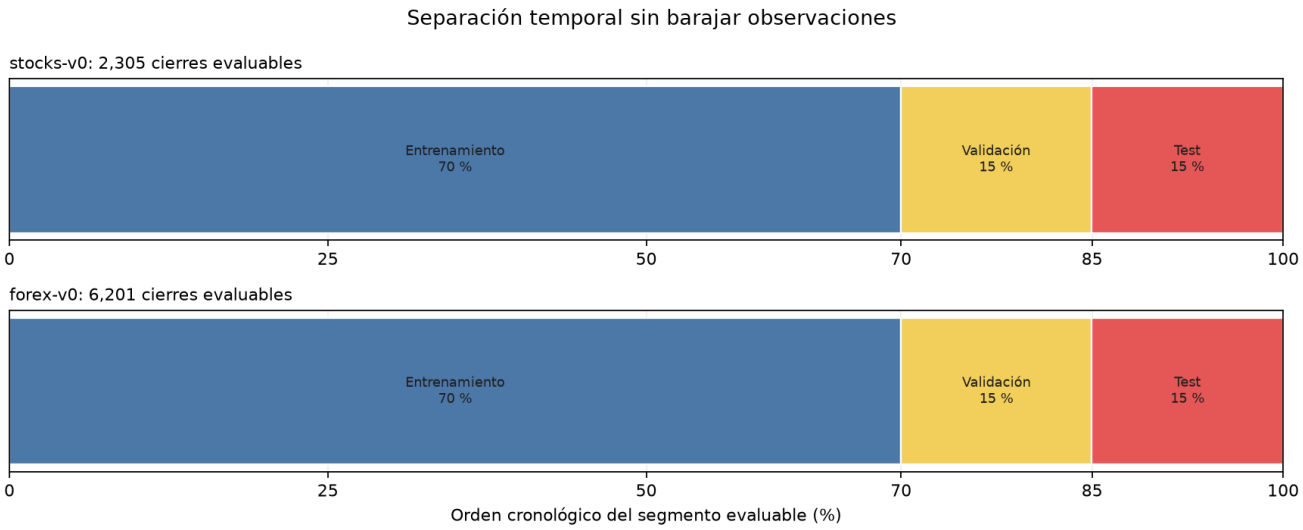
La Tabla 4 y la Figura 8 muestran el corte cronológico usado en cada serie. Se descuenta primero la ventana inicial necesaria para construir el estado; luego **se separan los cierres evaluables en 70 % entrenamiento, 15 % validación y 15 % test**, sin barajar fechas.

Tabla 4. *División cronológica de cierres evaluables por mercado.*

Mercado / tramo	Fechas incluidas	Puntos / transiciones	Porción
STOCKS_GOOGL / entrenamiento	07-07-2009 a 30-11-2015	1.613 / 1.612	70 %
STOCKS_GOOGL / validación	01-12-2015 a 13-04-2017	345 / 344	15 %
STOCKS_GOOGL / test	17-04-2017 a 29-08-2018	347 / 346	15 %
FOREX_EUR/USD / entrenamiento	02-01-2017 22:00 a 12-09-2017 16:00	4.340 / 4.339	70 %
FOREX_EUR/USD / validación	12-09-2017 17:00 a 06-11-2017 11:00	930 / 929	15 %
FOREX_EUR/USD / test	06-11-2017 12:00 a 29-12-2017 21:00	931 / 930	15 %

Nota: Cada par indica puntos de observación / transiciones recompensadas. Los primeros 30 cierres de Stocks y 24 de Forex son contexto, no transiciones evaluables. Segmentos contiguos, sin mezcla temporal.

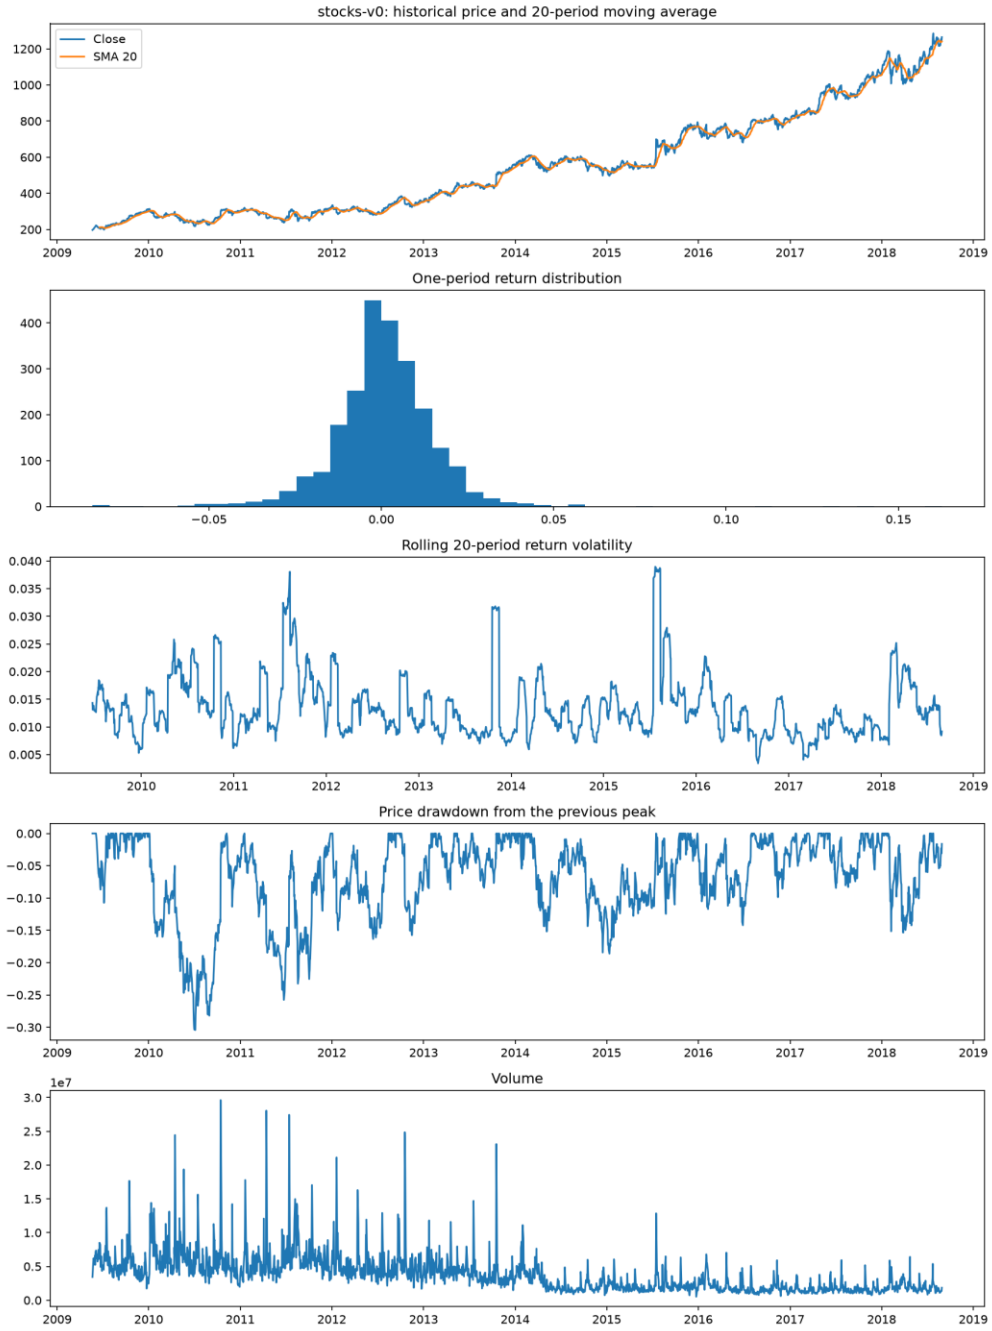
Figura 8. *Separación cronológica 70/15/15 para entrenamiento, validación y test.*



VIII. ANÁLISIS EXPLORATORIO DE LOS DATOS

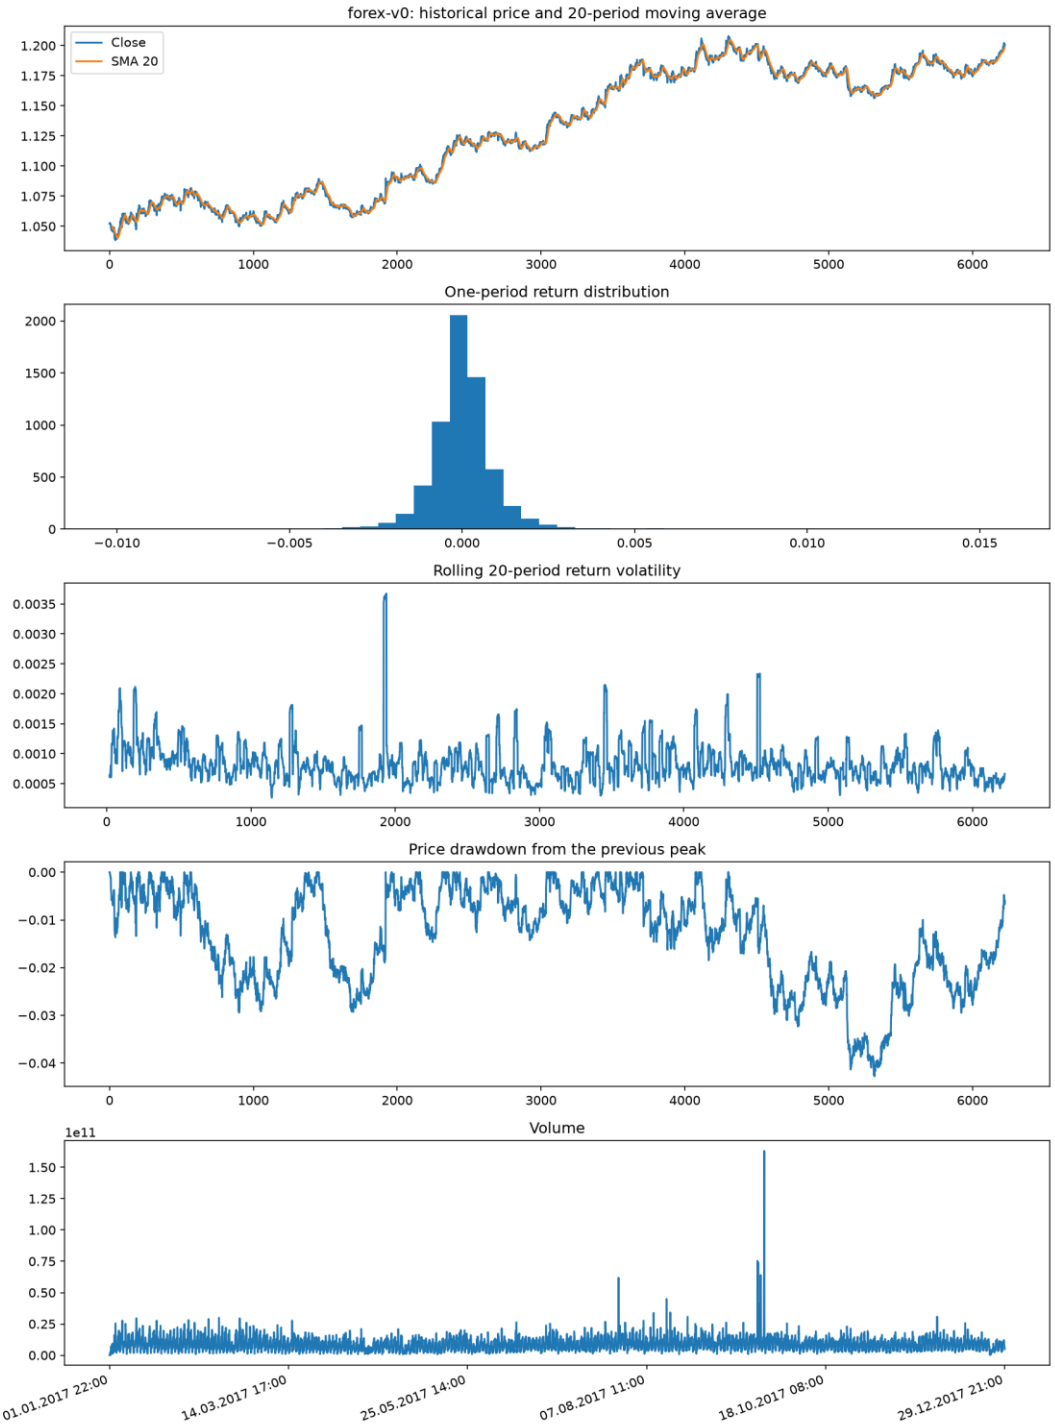
Se analizaron los CSV incluidos en **gym-anytrading** y se generaron los archivos **market_statistics.csv** y **market_eda.png** para ambos activos. **STOCKS_GOOGL** contiene 2.335 observaciones, de 22-05-2009 a 29-08-2018; descontando la ventana inicial de 30 cierres, hay 2.305 puntos disponibles para transiciones. Su retorno medio por sesión fue +0,0909 %, desviación estándar 1,5002 %, extremo mínimo −8,3774 % y máximo +16,2585 %. La volatilidad móvil de 20 períodos estuvo entre 0,3406 % y 3,8956 %. El precio de principio a fin subió 542,13 %, con máximo drawdown del precio −30,42 %; el CSV sí incluye Volume.

Figura 9. *Análisis exploratorio de precio, retornos, volatilidad, drawdown y volumen: STOCKS_GOOGL.*



FOREX_EUR/USD contiene 6.225 observaciones (6.201 transiciones tras la ventana inicial de 24), entre 01-01-2017 22:00 y 29-12-2017 21:00. El retorno medio por hora fue +0,00216 %, desviación 0,09218 %, mínimo −1,0213 % y máximo +1,5723 %. La volatilidad móvil de 20 retornos osciló entre 0,02668 % y 0,36755 %. El cambio de cierre de todo el año fue +14,11 % y el máximo drawdown del precio −4,28 %; también hay Volume. Los gráficos muestran las tendencias y caídas en precio/drawdown y los períodos de volatilidad alta y baja, junto con la SMA-20. Los resultados describen historias y no implican que una señal vaya a repetirse.

Figura 10. *Análisis exploratorio de precio, retornos, volatilidad, drawdown y volumen: FOREX_EUR/USD.*



Las figuras son exploratorias retrospectivas sobre la serie fuente completa, por lo que incluyen fechas que luego son held-out[6]. Se reportan para describir los datos, no para escoger umbrales con test; cualquier uso futuro del gráfico para cambiar indicadores o hiperparámetros después de ver el test sería fuga de información y requeriría un test nuevo.

Lectura de las Figuras 9 y 10: STOCKS_GOOGL muestra tendencia ascendente entre 2009 y 2018 (+542,13 %), interrumpida por caídas; el mayor drawdown fue -30,42 % entre 04-ene-2010 y 06-jul-2010. Retornos diarios: mediana +0,0681 %, media +0,0909 %, desviación 1,5002 %, sesgo 0,91; el 98 % central va de -4,03 % a +3,75 %, con extremos -8,38 % y +16,26 %. Volatilidad móvil de 20 sesiones: máximo 3,8956 % (20-ago-2015), mínimo 0,3406 % (30-sep-2016). FOREX_EUR/USD tuvo retorno anual +14,11 % y drawdown máximo -4,28 % entre 08-sep-2017 y 07-nov-2017. Retornos horarios: media +0,00216 %, desviación 0,09218 %, extremos -1,0213 % y +1,5723 %; volatilidad móvil máxima 0,3675 % (25-abr-2017 10:00) y mínima 0,0267 % (09-mar-2017 09:00). Volume aparece en los CSV, pero no es parte del estado. Estadísticas de la serie completa, se usarán para ajustar mirando test.

IX. IMPLEMENTACIÓN DEL ENTORNO

Se verificó en **PortfolioTradingEnv**, usado por **envs.make** para los IDs ya registrados **stocks-v0** y **forex-v0**. El entorno inicia con $100.000 y posición cero, acepta únicamente las tres acciones discretas, calcula la variación entre dos cierres consecutivos, descuenta el costo antes de calcular equity/recompensa, avanza un índice y termina el segmento de forma truncada. **info** registra fecha, precio, posición, patrimonio, profit factor, costo, retorno de mercado, drawdown[7] y turnover. Un cambio de 0 a 50 % cuesta $50 al inicio; de 0 a 100 % cuesta $100, con costo configurado de 10 bps sobre el patrimonio pretransacción y el cambio absoluto de exposición.

Ambos entornos pasan el verificador de **Gymnasium**; también se probaron el cálculo de costo/recompensa, el fin de segmento, el reset y la causalidad. **Los datos base se siguen obteniendo de gym-anytrading**, pero el reward/acción original de comprar-vender no se usa: el **wrapper** implementa explícitamente cartera, costos y exposición parcial.

Por otra parte, al observar el cierre Close[t] (y el estado derivado únicamente de cierres disponibles hasta t), DQN fija la exposición objetivo p[t]. El entorno cobra sobre el patrimonio previo V[t] el costo $c[t] = V[t] \times 0{,}001 \times |p[t]-p[t-1]|$. Después aplica el retorno de Close[t] a Close[t+1] a la nueva posición: $V[t+1] = V[t] \times (1-0{,}001|p[t]-p[t-1]|) \times (1+p[t](Close[t+1]/Close[t]-1))$. La recompensa y la

[6] Held-out: es un conjunto de datos históricos que se "reserva" y se mantiene completamente aislado durante la fase de diseño y entrenamiento de un modelo predictivo. Su único propósito es servir como la prueba de fuego final para evaluar el rendimiento real del modelo antes de arriesgar dinero real en los mercados.

[7] Drawdown: Mide la caída del valor de una inversión desde un máximo anterior. Si un portafolio aumenta de $100.000 a $150.000 y posteriormente cae a $120.000, el drawdown es −20 %. Por esta razón, no se debe evaluar una estrategia únicamente por su retorno.

próxima observación se devuelven después de avanzar al cierre t+1; ese nuevo cierre no intervino en la decisión p[t].

En el límite train/validación/test, se aceptan cierres anteriores como contexto de una ventana móvil; los movimientos recompensados se restringen al tramo actual. Los episodios de trading duran una pasada secuencial por el tramo y el algoritmo reinicia el episodio para alcanzar el número de pasos solicitado.

La Tabla 5 traduce el ciclo de PortfolioTradingEnv a las variables que conserva, las operaciones por paso y la salida que recibe Stable-Baselines3. La fila de actualización numérica usa la transición real del 24 al 25 de abril mostrada en la Figura 6.

Tabla 5. *Ciclo de una transición en PortfolioTradingEnv.*

Paso	Estado / operación	Resultado del entorno
reset()	V[0] = USD 100.000; exposición = 0; peak inicial.	Devuelve primera observación causal e inicializa patrimonio.
Acción	p[t] = {0; 0,5; 1}; turnover = |p[t] - p[t-1]|.	Posición aplicada de Close[t] a Close[t+1].
Costo y mercado	c[t] = V[t] × 0,001 × turnover; R_m = Close[t+1] / Close[t] - 1.	Se descuenta comisión y aplica retorno a nueva exposición.
Nuevo patrimonio	V[t+1] = V[t] × (1 - 0,001 × turnover) × (1 + p[t] × R_m).	Actualiza patrimonio, posición, máximo histórico y drawdown.
Reward / fin	r[t+1] = ln(V[t+1] / V[t]).	Devuelve S[t+1], reward e indicador de fin de segmento.

X. DISEÑO DE LA RECOMPENSA

La función de recompensa es uno de los elementos centrales del proyecto. Una primera alternativa puede ser utilizar directamente el retorno:

$$rt = (Vt+1 - Vt) / Vt$$

Donde Vt representa el valor de la inversión. También pueden utilizarse alternativas como el retorno logarítmico:

$$rt = \log(Vt+1 / Vt)$$

La recompensa debe incorporar correctamente los costos de transacción.

Iteración de diseño: Primero se definió retorno simple neto de costo, V[t+1]/V[t]−1, y se añadió la alternativa logarítmica, log(V[t+1]/V[t]), para hacer aditiva la recompensa de varios intervalos y mantener explícita la deducción de fees[8]. Se entrenó el agente final con log_return, drawdown_penalty=0,5 configurado pero no aplicado en este modo, y costo de 10 bps. El DQN resultante dio reward acumulado de validación −0,012946 (STOCKS_GOOGL) y −0,017036 (FOREX_EUR/USD). El backtest held-out dio retornos de +7,73 % y +1,22 %, respectivamente.

La iteración de implementación reemplaza la recompensa/acciones originales de gym-anytrading, no modelaban esta cartera 0/50/100 con el costo solicitado, por patrimonio neto de costos y log-return. El código también ofrece simple_return y drawdown_adjusted; no hay checkpoint ni registro MLflow de entrenamiento controlado con esos rewards, por lo que no se les atribuyen resultados ni se afirma una mejora estadística entre versiones. Un experimento ablation[9] válido debe reentrenar ambas variantes con las mismas fechas, semillas e hiperparámetros, usar validación para elegir y reservar otro test intacto.

Por otra parte, de acuerdo a las posiciones observadas, **STOCKS_GOOGL**: en validación eligió efectivo 191/344 pasos, 50 % 146/344 y 100 % solo 7/344; realizó 41 cambios y pagó $2.390,20. En test: 162/346 pasos en efectivo, 168/346 al 50 % y 16/346 al 100 %, 47 cambios y $2.868,32 en fees. Por tanto estuvo fuera del mercado aproximadamente 47 % del test y redujo exposición durante el fuerte avance de esa ventana, perdiendo frente a buy-and-hold. No es operación excesiva frente a random, pero sus costos superaron ampliamente los $100 de la estrategia pasiva.

FOREX_EUR/USD eligió 50 % durante 921/929 pasos de validación (ocho en efectivo, ninguno al 100 %) con un solo cambio y $50 de costo; en test eligió 50 % durante 790/930 pasos y efectivo durante 140, sin usar el 100 %, con un cambio y $50. No hay evidencia de churn o de operar cada movimiento; sí de una política casi constante de exposición parcial. El resultado no permite diagnosticar con certeza «búsqueda de retornos cortos»: el reward es log-return aditivo y los gráficos/equity describen el período entero. No se observa reward hacking como una explotación no financiera; el riesgo de diseño es que maximizar recompensa histórica y escoger una acción dominante no garantizan generalización ni preferencias de riesgo adecuadas.

La Tabla 6 contrasta riesgos de diseño con lo que aparece en los resultados de validación y test. Los conteos describen estas ventanas históricas: no prueban por sí solos una causa, estrategia de corto plazo ni explotación de la recompensa.

Tabla 6. *Diagnóstico de riesgos del diseño de la recompensa.*

[8] Fee: es una comisión, tarifa o cargo económico que pagas a intermediarios, plataformas o asesores por gestionar tu dinero o ejecutar transacciones.

[9] Experimento ablation: Consiste en eliminar, apagar o alterar una parte específica de un sistema para entender qué función cumple y cómo afecta el rendimiento general.

Riesgo a vigilar	Evidencia observada	Interpretación prudente
Demasiado efectivo	GOOGL: 162/346 pasos a 0 %, media 28,9 %; forex: 140/930, media 42,5 %.	En GOOGL coincidió con avance y menor retorno que buy-and-hold; no prueba error en cada decisión.
Exceso de operaciones	DQN: 47 cambios/USD 2.868,32 GOOGL; 1/USD 50 forex. Random: 239/619 y USD 15.279,48/USD 34.936,03.	No hay churn frente a random; fees GOOGL superan USD 100 de buy-and-hold.
Perseguir retorno corto	Reward suma log-retornos netos; reportes agregan trayectoria completa.	No se infiere preferencia de corto plazo sin decisiones/rewards fechados.
Riesgo asumido	DQN MDD: -7,07 % GOOGL, -0,99 % forex; mejor que buy-and-hold (-15,36 %/-1,97 %) y random (-23,15 %/-32,23 %).	Sin cortos ni apalancamiento; un test no caracteriza riesgo futuro.
Debilidad del reward	Fees por turnover; drawdown_penalty=0,5 no aplica a log_return, sí a drawdown_adjusted.	No hay evidencia de reward hacking; sobreajuste requiere otras ventanas/semillas.

XI. ALGORITMO DE REINFORCEMENT LEARNING

El algoritmo utilizado es **Deep Q-Network** de **Stable-Baselines3**, **política MLP para el vector de siete indicadores y tres Q-values para las exposiciones**. **La red usa dos capas ocultas de 128 unidades** (net_arch [128,128]). Los dos checkpoints finales fueron entrenados en CPU por 200.000 pasos con learning_rate=0,0001; batch_size=64; gamma=0,99; replay buffer=50.000; learning_starts=2.000; train_freq=4; gradient_steps=1; actualización de target cada 1.000 pasos; epsilon-greedy inicial 1,0, decaimiento durante 20 % de los pasos y epsilon final 0,05. La semilla del agente y de la evaluación fue 42. No hubo una cantidad fija de episodios: se detuvo por pasos; los logs de Monitor registraron 124 episodios en STOCKS_GOOGL y 44 en FOREX, con longitudes medias respectivas de 1.612 y 4.339 pasos.

En MLflow, la recompensa media móvil de entrenamiento registrada fue +1,3063 para STOCKS_GOOGL y −0,3486 para FOREX_EUR/USD; son medias de episodios de entrenamiento con exploración, no retornos de inversión comparables entre activos. La evaluación determinista de un episodio completo en validación fue −0,012946 y −0,017036 de reward. La exploración final del checkpoint fue 0,05, mientras que la evaluación usa predicción determinista.

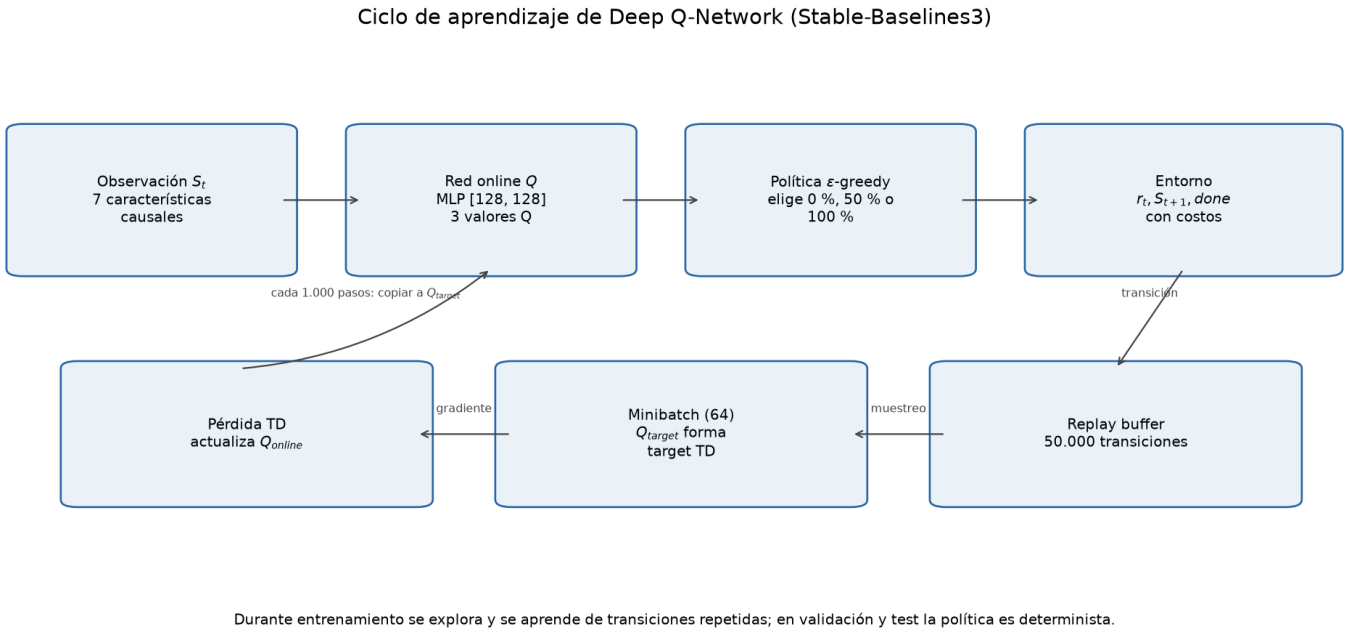
Para cada fuente se reservó cronológicamente 70 % para entrenamiento, 15 % para validación y 15 % final para test. Configuración fija: semilla 42, 200.000 pasos, misma red/hiperparámetros y 10 bps; MLflow guardó los parámetros, métricas y checkpoint. `**rlgames-sb train --config configs/stocks_dqn.yaml**` y el equivalente `**forex_dqn.yaml**` entrenan; la evaluación que ejecuta `**train**`

usa validation, no test. Los logs identifican los runs de entrenamiento como 184aadb472ed466db94112d1803fab94 (STOCKS_GOOGL) y 068ebc1602b14cce863b614724a3540f (FOREX_EUR/USD).

También se ejecutó una búsqueda exploratoria Optuna de 10 trials × 30.000 pasos en cada configuración, puntuados en validación. Sus mejores rewards reportados fueron +0,050437 en acciones y 0,0 en FOREX. Sin embargo, el checkpoint de 200.000 pasos conservó los hiperparámetros base del YAML (lo confirma su metadata); no se copiaron a ese checkpoint los parámetros ganadores de Optuna. Una reproducción debe distinguir esos resultados de búsqueda del resultado final y no consultar el conjunto de test durante selección.

La Figura 11 representa el ciclo DQN usado por Stable-Baselines3: interacción con el entorno, almacenamiento de transiciones, muestreo de minibatches y actualización de redes online/target. Arquitectura e hiperparámetros se describen en este apartado.

Figura 11. *Flujo de interacción, replay buffer y actualización de redes DQN.*



XII. BASELINES

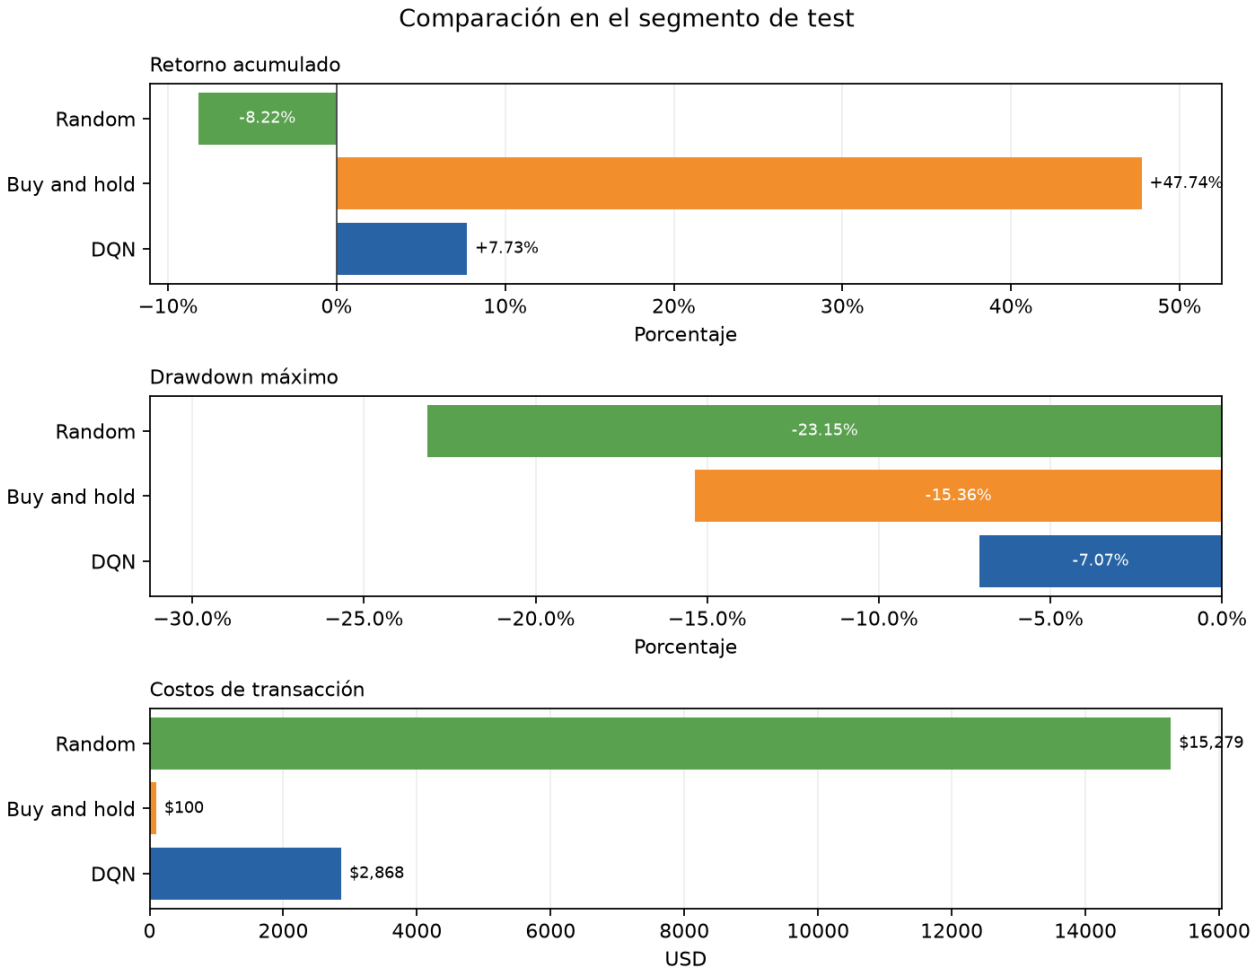
Se compararon las predicciones deterministas con (a) **buy**-and-**hold**, que entra al 100 % desde el primer cierre y mantiene la posición, y (b) **random**, que muestrea 0/50/100 % con semilla 42. En test STOCKS_GOOGL el DQN rindió +7,73 %, buy-and-hold +47,74 % y random −8,22 %. En FOREX: +1,22 %,

+3,50 % y −32,20 %. Así, **DQN superó a random en ambos mercados**, pero no a buy-and-hold en retorno; redujo drawdown frente a buy-and-hold, especialmente en FOREX. Esto no prueba rentabilidad futura ni superioridad general del agente.

Comprar y vender: cada política comienza con $100.000 y se recorre exactamente el mismo segmento y fechas por activo, con las mismas reglas de transición, cierres, ventanas, fee de 10 bps y cálculo de retorno/drawdown. A buy-and-hold se le cobra el cambio inicial 0→100 % ($100); **la política random usa la misma acción discreta y semilla fijada y paga turnover en cada rebalanceo**; **DQN se ejecuta sin exploración**. El número de cambios y el fee total reportados permiten apreciar el efecto de costos que ocultaría una comparación de recompensas solamente.

La Tabla 8 consolida **métricas de validación y test de DQN, buy-and-hold y política aleatoria para ambos mercados**. La Figura 12 resume retorno, drawdown y costos de STOCKS_GOOGL test: buy-and-hold logra mayor retorno y DQN menor drawdown que esa referencia en esta ventana.

Figura 12. *Retorno, drawdown máximo y costos por estrategia en el test de STOCKS_GOOGL.*



XIII. PROTOCOLO DE ENTRENAMIENTO Y EVALUACIÓN

La validación cronológica se usó para evaluación (una pasada determinista) y para la búsqueda de hiperparámetros; el tramo final de test no se usó para entrenar, ajustar reward ni seleccionar parámetros. **STOCKS_GOOGL**: estados de entrenamiento 07-07-2009 a 30-11-2015; validación 01-12-2015 a 13-04-2017 (344 intervalos evaluados); test 17-04-2017 a 29-08-2018 (346 intervalos). **FOREX_EUR/USD**: entrenamiento 02-01-2017 22:00 a 12-09-2017 16:00; validación 12-09-2017 17:00 a 06-11-2017 11:00 (929 intervalos); test 06-11-2017 12:00 a 29-12-2017 21:00 (930 intervalos). El primer reward corresponde al movimiento desde el cierre de decisión de inicio al cierre siguiente.

Las fechas y resultados dependen de los CSV distribuidos con la versión instalada de gym-anytrading. El test es una única ventana histórica y un único seed, por lo que mide ese episodio, no incertidumbre estadística. Los reportes presentan simultáneamente retorno, riesgo, fees y posición para no seleccionar al agente solo por reward.

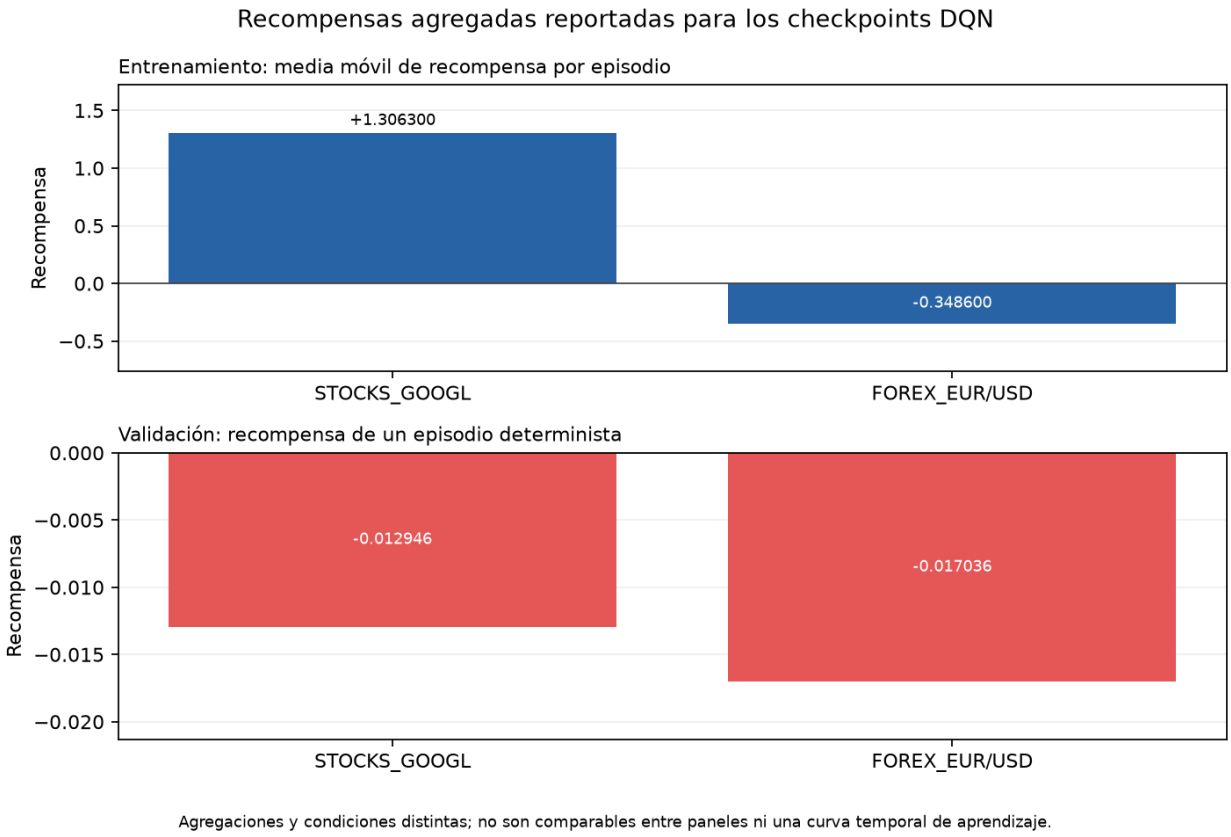
La Tabla 7 presenta agregados disponibles de entrenamiento y evaluación para los dos checkpoints; Figura 13 los visualiza. **El entrenamiento se detuvo por 200.000 pasos, no por épocas prefijadas**. No es curva temporal: no hay secuencia de rewards por paso/episodio para reconstruir aprendizaje ni afirmar convergencia.

Tabla 7. *Agregados disponibles de entrenamiento, validación y test.*

Etapa	STOCKS_GOOGL	FOREX_EUR/USD
Entrenamiento	200.000 pasos; 124 episodios; longitud media 1.612; reward medio móvil +1,3063; epsilon final 0,05.	200.000 pasos; 44 episodios; longitud media 4.339; reward medio móvil -0,3486; epsilon final 0,05.
Validación	1 episodio determinista; reward total -0,012946.	1 episodio determinista; reward total -0,017036.
Test reservado	No usado al entrenar/seleccionar; retorno +7,73 %; MDD -7,07 %.	No usado al entrenar/seleccionar; retorno +1,22 %; MDD -0,99 %.

Nota. Training agrega episodios con exploración; validation es una pasada determinista completa. No son agregaciones idénticas. training_summary.csv guarda agregados, no rewards por episodio.

Figura 13. *Rewards agregados reportados; no representa evolución temporal del aprendizaje.*



XIV. MÉTRICAS

La tabla siguiente incluye los tramos de validación y held-out test (valor final tras costo, max drawdown calculado sobre el equity curve, suma nominal de costos, cambios de posición y exposición media). Capital inicial: $100.000. El retorno es V_final/V_inicial−1; el drawdown máximo es el mínimo de V_t/máximo(V_0…V_t)−1. Validación es útil para diagnóstico/selección; test es el resultado final que no debe guiar nuevos ajustes. Los valores se recalcularon desde los checkpoints y son consistentes con el archivo del proyecto: **reports/*-final/strategy_summary.csv**.

Tabla 8. *Métricas de validación y test por estrategia, mercado y segmento.*

Mercado / tramo	Estrategia	Retorno	MDD	Costos ($)	Cambios	Expo. media
STOCKS_GOOGL / validación	DQN	-1,29 %	-7,04 %	2.390,20	41	23,3 %
STOCKS_GOOGL / validación	Buy & hold	+7,09 %	-14,21 %	100,00	1	100,0 %
STOCKS_GOOGL / validación	Aleatorio	-2,34 %	-13,21 %	14.690,39	237	50,0 %

STOCKS_GOOGL / test	DQN	+7,73 %	-7,07 %	2.868,32	47	28,9 %
STOCKS_GOOGL / test	Buy & hold	+47,74 %	-15,36 %	100,00	1	100,0 %
STOCKS_GOOGL / test	Aleatorio	-8,22 %	-23,15 %	15.279,48	239	50,0 %
FOREX_EUR/USD / validación	DQN	-1,69 %	-1,82 %	50,00	1	49,6 %
FOREX_EUR/USD / validación	Buy & hold	-3,17 %	-3,61 %	100,00	1	100,0 %
FOREX_EUR/USD / validación	Aleatorio	-36,01 %	-36,01 %	33.983,41	619	50,4 %
FOREX_EUR/USD / test	DQN	+1,22 %	-0,99 %	50,00	1	42,5 %
FOREX_EUR/USD / test	Buy & hold	+3,50 %	-1,97 %	100,00	1	100,0 %
FOREX_EUR/USD / test	Aleatorio	-32,20 %	-32,23 %	34.936,03	619	50,4 %

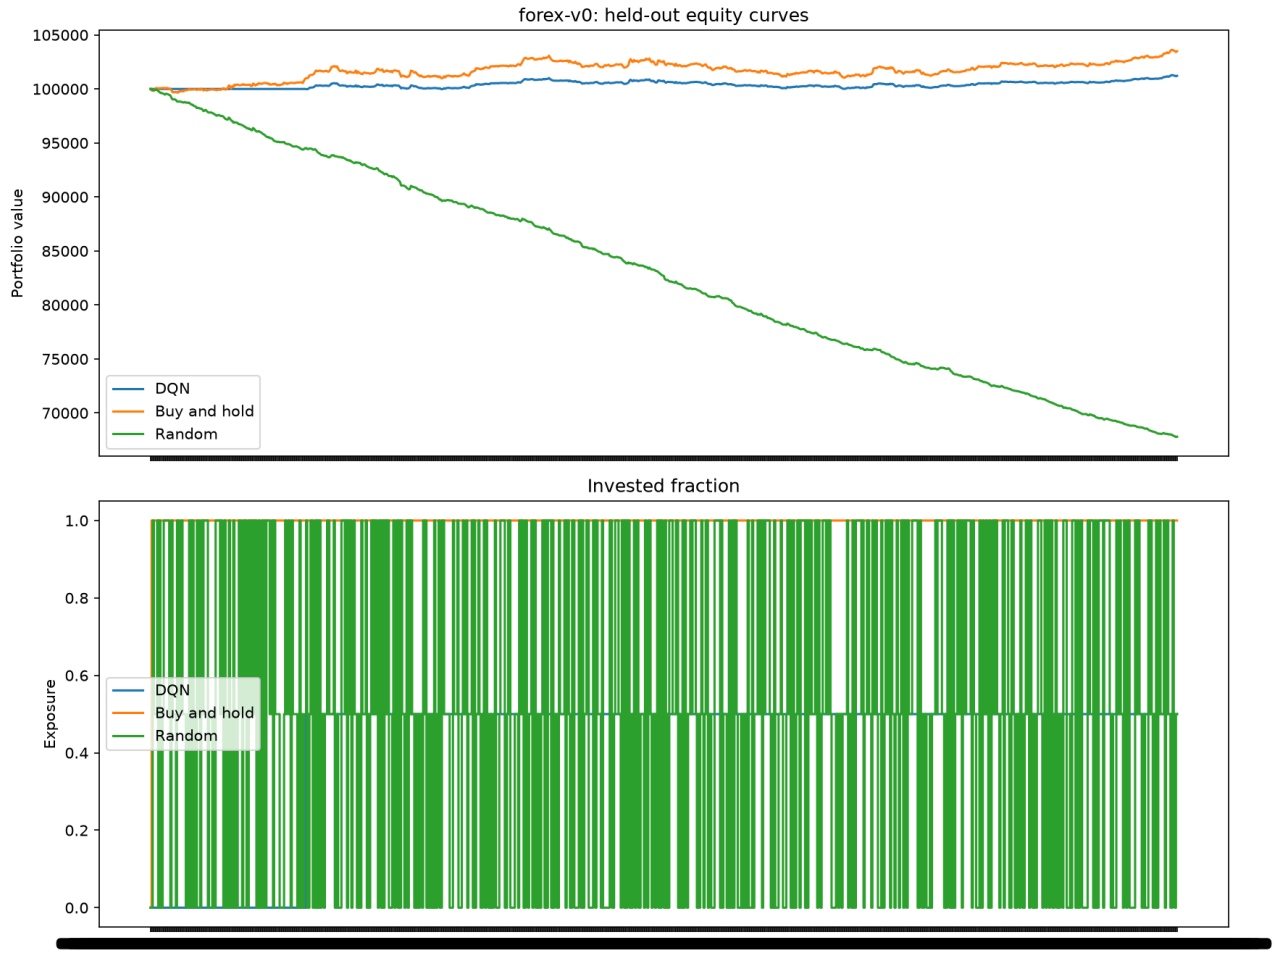
En test, el valor final fue: **STOCKS_GOOGL DQN** $107.281, buy-and-hold $147.742 y random $91.782; **FOREX_EUR/USD DQN** $101.217, buy-and-hold $103.495 y random $67.800. La pérdida de buy-and-hold en drawdown frente al DQN no compensa la gran brecha de retorno en STOCKS_GOOGL; en FOREX_EUR/USD el riesgo absoluto fue bajo para ambos, pero buy-and-hold obtuvo algo más de retorno.

Se insertan a continuación las curvas calculadas directamente del equity de cada paso del test. Cada figura superpone DQN, buy-and-hold y random, e incluye el panel temporal de exposición. Los CSV detallados (equity_curves.csv) registran fecha, patrimonio, posición, costo y turnover por decisión.

Figura 14. *STOCKS_GOOGL: equity curve y exposición en test (17-04-2017 a 29-08-2018).*



Figura 15. *FOREX_EUR/USD: equity curve y exposición en test (06-11-2017 a 29-12-2017).*



XV. RESULTADOS

Las figuras insertadas en la sección anterior muestran valor de cartera en dólares arriba y exposición abajo. En **STOCKS_GOOGL** el buy-and-hold captura el rally de test y finaliza muy por encima del DQN, aunque con drawdown −15,36 % frente a −7,07 %. El agente reduce la volatilidad de trayectoria al estar en efectivo/50 % durante la mayoría del tramo, a costa de dejar escapar parte del aumento. En **FOREX_EUR/USD**, buy-and-hold también gana más (+3,50 % frente a +1,22 %), pero la distancia de retornos es menor; el DQN mantiene max drawdown bajo (−0,99 % versus −1,97 %). Random es inferior en ambos, con alta rotación y drawdown.

Los costos confirman una limitación: en **STOCKS_GOOGL DQN** pagó $2.868,32 (47 cambios), frente a $100 de buy-and-hold; random pagó $15.279,48 (239 cambios). En **FOREX, el DQN** pagó $50 por un solo cambio, buy-and-hold $100 y random $34.936,03 por 619 cambios. El comportamiento inesperado más claro es la política muy conservadora/casi estacionaria en FOREX: nunca eligió exposición total en validación ni test, y mantuvo 50 % durante 921/929 pasos de validación. En

STOCKS_GOOGL el mismo checkpoint alternó más y solo usó 100 % en 16/346 pasos de test. Es una política discreta sesgada a exposición baja, no una estrategia dinámica de alta frecuencia.

No se ejecutó una ablación de reward con checkpoints equivalentes para simple_return y drawdown_adjusted; el comparador empírico disponible es log_return contra los dos baselines. Por ello, no se atribuye a una variante de reward una curva o mejora no observada. Un estudio de reward debe mantener fijos división, semilla, costos, pasos y red, volver a entrenar cada variante y reportar el nuevo test solo una vez. Los CSV y curvas son más informativos que el reward porque la recompensa no es una utilidad financiera completa.

XVI. REFLEXIÓN

¿Cuál fue el resultado que más le sorprendió?

El resultado más sorprendente fue la diferencia por activo: el DQN ganó a random en ambos tests, pero buy-and-hold obtuvo seis veces aproximadamente el retorno del DQN en STOCKS_GOOGL (+47,74 % versus +7,73 %). La estrategia DQN sí limitó el drawdown, por lo que el retorno aislado no cuenta toda la historia. En FOREX, la elección fue casi constante al 50 %, pese a que el algoritmo podía escoger tres posiciones.

¿Qué decisión metodológica tuvo mayor impacto en el agente?

La decisión más importante fue la separación temporal y la transición causal cierre t→cierre t+1; después, incluir el costo de turnover. Esto permite medir un resultado no usado para ajustar el modelo y hace visible que en STOCKS_GOOGL operar 47 veces costó $2.868,32. Sin fees, el agente podría aparentar una mejora que se pierde al ejecutar cambios.

¿Qué cambiaría si tuviera que repetir el experimento?

Repetiría el estudio con varios seeds y ventanas walk-forward, y con un test final nuevo cada vez que se modifique el reward o la arquitectura. Evaluaría umbrales/regímenes solo en training/validation, incorporaría spread/slippage realistas y compararía la política con una referencia de exposición comparable al riesgo. Antes de aumentar la red, comprobaría la estabilidad de la política y de las métricas en diferentes periodos.

¿Qué comportamiento del agente no logró explicar completamente?

La preferencia casi fija por 50 % en FOREX y el escaso uso de 100 % no se explican completamente por un único estado/reward, dado un solo seed y un solo año. Para investigarlo inspeccionaría valores Q por acción y estados en fechas concretas, repetiría seeds y separaría el efecto

de la caída de epsilon, la muestra de replay y la forma del reward. El dato observado es la distribución de acciones, no una explicación causal concluyente.

¿Cuál fue la principal diferencia entre lo aprendido en Reinforcement Learning y su aplicación a este problema?

La diferencia principal frente al MDP ideal es la no estacionariedad: el mercado histórico no repite una distribución fija de transiciones/recompensas, y siete indicadores de precio no hacen que todos los factores económicos sean observables. La experiencia de replay procede de una trayectoria finita y reutilizada; converger en entrenamiento no demuestra que la política generalice a otro régimen o a ejecución real.

¿Qué limitaciones y problemas se encontraron en el proyecto?

La respuesta a la pregunta central tiene dos partes. Frente a una estrategia simple como operar al azar, el agente sí aprendió algo valioso: la disciplina de operar poco y mantenerse invertido la mayor parte del tiempo. Frente a comprar (buy) y mantener (hold), en cambio, no logró una ventaja: ganó menos en retorno y empató en riesgo ajustado. Es un resultado negativo en la comparación más exigente, pero el proceso permitió entender por qué ocurre y evitar conclusiones engañosas, como la ventaja aparente de la validación. El DQN no superó a buy-and-hold en retorno final.

El trabajo tiene varias limitaciones. Se usó un solo activo con una tendencia alcista muy fuerte en todos los períodos, un escenario en el que cualquier salida del mercado tiene un costo de oportunidad alto y que favorece a comprar y mantener. La validación fue de un solo año y buena parte de su resultado se decidió en pocos días, lo que hizo frágil la elección de la penalización. El modelo de costos es simple: no incluye diferencias entre precio de compra y de venta, impacto en el precio ni impuestos, y la ejecución al mismo precio de cierre en que se decide es una simplificación. Los indicadores son sencillos y los hiperparámetros de DQN no se ajustaron. Finalmente, la reproducción bit a bit se comprobó en CPU en una misma máquina; en otro equipo pueden aparecer diferencias pequeñas de cálculo y en GPU el entrenamiento es determinista.

Entre los problemas encontrados durante el proyecto, además del reward hacking, se destacan dos. La elección de la penalización quedó primero en el borde de los valores probados, lo que obligó a ampliar la búsqueda. Y la verificación inicial del agente congelado usaba el hash del archivo del modelo, que cambia cada vez que se guarda aunque los pesos sean iguales; se corrigió para usar el hash de los pesos, de modo que otra persona que reproduzca el entrenamiento pase la verificación

XVII. REPRODUCIBILIDAD

De proyecto base se reutilizaron el registro **Stable-Baselines3 DQN** y las interfaces del **CLI/configuración/tracking** de **rl_games_sb**; el código adicional acotado está en **trading.py** (entorno de cartera, features, EDA y backtest), y **envs.py** enruta los mismos IDs **stocks-v0/forex-v0** a ese entorno. **experiments.py** reutiliza **train/tune/evaluate_policy** y registra **MLflow**; **registry.py** crea y carga los checkpoints; las especificaciones están en **configs/stocks_dqn.yaml** y **configs/forex_dqn.yaml**. No se creó un agente DQN alternativo ni un segundo proyecto de aprendizaje.

Los resultados de reproducibilidad se generaron en **reports/stocks-eda**, **reports/forex-eda**, **reports/stocks-final** y **reports/forex-final**. Las curvas son artefactos del mismo código y los checkpoints **saves/dqn_stocks-v0.zip** y **saves/dqn_forex-v0.zip**.

El **README** del proyecto ya contiene las instrucciones y se ejecutaron las rutas indicadas. En Windows, desde rl_games_sb: `**uv sync**`; generar EDA con `**uv run rlgames-sb analyze --env stocks-v0 --output reports\stocks-eda**` y equivalente forex; entrenar con `**uv run rlgames-sb train --config configs\stocks_dqn.yaml**` y `**configs\forex_dqn.yaml**`; comparar en test con `**uv run rlgames-sb backtest --config configs\stocks_dqn.yaml --output reports\stocks-final**` y equivalente forex. Opcionalmente, `**uv run rlgames-sb tune --config ... --trials 10**` usa validación, nunca el test.

Las semillas de configuración son 42; el DQN recibe seed=42, los ensayos Optuna usan 42 + número de trial y las políticas random se reinician con seed 42. Las dependencias quedan fijadas por **pyproject.toml** y **uv.lock**; los datos son los CSV incluidos con **gym-anytrading** y no se descargan. Las ejecuciones finales están en MLflow (experimentos **trading_stocks_dqn** y **trading_forex_dqn**; IDs de run documentados arriba). Los checkpoints se guardan por agente/entorno. Para cambiar reward/hiperparámetros se debe eliminar o separar explícitamente el checkpoint previo antes de reentrenar, pues el comando de train reanuda el save existente.

XVIII. REFERENCIAS

Henderson, P., Islam, R., & Bachman, P. (2018). *Deep reinforcement learning that matters.* AAAI.

Huang, S., Dossa, R., & Raffin, A. (2022). *The 37 implementation details of proximal policy optimization.* ICLR Blog Track.

Lapan, M. (2020). *Deep Reinforcement Learning Hands-On.* Packt.

OpenAI. (2018). *Spinning up as a deep RL researcher.*

Sutton, R., & Barto, A. (2018). *Reinforcement learning: An introduction.* MIT Press.